

# CLASIFICACIÓN DE TUMORES CEREBRALES CON CNN

Kevin Perez Alvarez

## Índice

|                                |    |
|--------------------------------|----|
| Introducción .....             | 2  |
| Datos .....                    | 3  |
| Marco teórico .....            | 4  |
| Estructura de los datos .....  | 6  |
| Metodología.....               | 7  |
| Resultados .....               | 9  |
| Discusión y limitaciones ..... | 10 |
| Conclusiones .....             | 12 |
| Extra.....                     | 12 |

## Introducción

Los tumores cerebrales representan una de las patologías neurológicas con mayor impacto en la morbilidad y mortalidad a nivel mundial, debido a su alta complejidad diagnóstica y a la necesidad de una intervención oportuna. El diagnóstico temprano y preciso es fundamental para definir el tratamiento adecuado y mejorar el pronóstico del paciente. En la práctica clínica, la resonancia magnética (Magnetic Resonance Imaging, MRI) es una de las técnicas de imagen más utilizadas para la evaluación de lesiones intracraneales, ya que proporciona una excelente resolución anatómica y contraste de tejidos blandos.


Sin embargo, la interpretación de imágenes de MRI depende en gran medida de la experiencia del especialista, lo que puede introducir variabilidad interobservador y aumentar el tiempo requerido para el diagnóstico, especialmente en contextos clínicos con alta carga de trabajo. En este escenario, las técnicas de aprendizaje profundo (deep learning), y en particular las redes neuronales convolucionales (Convolutional Neural Networks, CNN), han demostrado un alto desempeño en tareas de clasificación y reconocimiento de patrones en imágenes médicas, ofreciendo una herramienta de apoyo al diagnóstico clínico.

El objetivo principal de este trabajo es desarrollar y evaluar una red neuronal convolucional capaz de clasificar automáticamente imágenes MRI cerebrales en las cuatro categorías mencionadas, utilizando técnicas de preprocesamiento, regularización y entrenamiento supervisado. El modelo propuesto busca alcanzar un equilibrio entre precisión y capacidad de generalización, con el fin de demostrar el potencial de las CNN como sistemas de apoyo al diagnóstico en el ámbito de la imagenología médica.

Finalmente, este proyecto también contempla la implementación del modelo entrenado en un entorno de despliegue mediante una API y una interfaz web, lo que permite explorar su posible aplicación práctica en sistemas clínicos reales y plataformas de diagnóstico asistido por inteligencia artificial.

## Datos

Se utiliza el conjunto de datos “Brain Tumor MRI Dataset (Glioma, Meningioma, Pituitary, No Tumor)”, el cual contiene 12,064 imágenes de resonancia magnética cerebral T1-ponderadas, organizadas en cuatro clases: glioma, meningioma, tumor pituitario y ausencia de tumor. Estas categorías representan los tipos de tumores intracraneales más comunes, así como casos normales, permitiendo abordar el problema como una tarea de clasificación multiclase.



*1 MRI con glioma*

*2 MRI sin tumor*

Este conjunto de datos se puede revisar y obtener en:

<https://data.mendeley.com/datasets/zwr4ntf94j/5>

## Marco teórico

### Resonancia Magnética Cerebral (MRI)

La resonancia magnética (Magnetic Resonance Imaging, MRI) es una técnica de imagen médica no invasiva que utiliza campos magnéticos y ondas de radio para generar imágenes detalladas de las estructuras internas del cuerpo humano. Las imágenes T1-ponderadas destacan por proporcionar un buen contraste anatómico, permitiendo una visualización clara de la morfología cerebral y de lesiones tumorales.

### Tumores Cerebrales

Los tumores cerebrales son proliferaciones anormales de células dentro del cráneo y pueden clasificarse según su origen, comportamiento biológico y localización. Entre los tipos más comunes se encuentran:

**Gliomas:** Tumores originados en células gliales, generalmente de crecimiento infiltrativo y con alto potencial maligno.

**Meningiomas:** Tumores que se desarrollan a partir de las meninges, usualmente benignos y bien delimitados.

**Tumores pituitarios:** Lesiones que afectan la glándula hipófisis, con posibles alteraciones endocrinas.

**Casos sin tumor:** Imágenes de referencia que representan estructuras cerebrales normales.

La diferenciación precisa entre estos tipos de tumores es crucial, ya que cada uno requiere estrategias terapéuticas distintas.

### Redes Neuronales Convolucionales (CNN)

Las redes neuronales convolucionales (Convolutional Neural Networks, CNN) son una arquitectura especializada de redes neuronales profundas diseñada para el procesamiento de datos con estructura espacial, como las imágenes. Las CNN son capaces de aprender representaciones progresivamente más abstractas, pasando de características simples (bordes, contrastes) a patrones complejos (formas tumorales), lo que las hace especialmente efectivas en el análisis de imágenes médicas.

## Clasificación Multiclase con CNN

La clasificación multiclase consiste en asignar una instancia de entrada a una única clase entre múltiples categorías posibles. En este proyecto, el problema se plantea como una clasificación multiclase de imágenes MRI en cuatro categorías: glioma, meningioma, tumor pituitario y ausencia de tumor.


Para este tipo de tareas, es común utilizar una función de activación softmax en la capa de salida, que produce una distribución de probabilidad sobre las clases, y la función de pérdida categorical cross-entropy, adecuada para problemas de clasificación multiclase. Estas configuraciones permiten al modelo no solo predecir la clase más probable, sino también estimar la confianza asociada a cada predicción.

## Estructura de los datos

Se realizó un análisis de la estructura del conjunto de datos empleado. El dataset de imágenes cuenta con más de 12 000 imágenes de resonancia magnética cerebral, distribuidas en cuatro clases: glioma, meningioma, tumor pituitario y sin tumor. Adicionalmente, el conjunto de datos se encuentra previamente dividido en subconjuntos de entrenamiento (train) y prueba (test), siguiendo una proporción aproximada 80/20.

La correcta organización de los datos es un aspecto fundamental para el entrenamiento de redes neuronales convolucionales, particularmente al utilizar generadores de imágenes como `flow_from_directory`, los cuales dependen directamente de la estructura jerárquica de carpetas para asignar las etiquetas de clase. En este trabajo, los datos fueron organizados siguiendo una arquitectura de directorios clara y estandarizada, como se muestra a continuación:

data/



Cada subdirectorio representa una clase específica, conteniendo exclusivamente imágenes correspondientes a dicha categoría. Esta organización permite que el modelo asigne automáticamente las etiquetas durante el proceso de entrenamiento y evaluación, garantizando consistencia entre los datos y las salidas del clasificador.

# Metodología

## Preprocesamiento de imágenes

Con el objetivo de garantizar la homogeneidad de las imágenes de entrada y mejorar la capacidad de generalización del modelo, se aplicó una etapa de preprocesamiento y aumento de datos (*data augmentation*) utilizando la clase ImageDataGenerator de Keras.

Todas las imágenes fueron redimensionadas a un tamaño uniforme de **224 × 224 píxeles**, permitiendo su compatibilidad con la arquitectura de la red y reduciendo la complejidad computacional. Asimismo, los valores de intensidad de los píxeles fueron normalizados mediante un factor de reescalamiento de 1/225

Para incrementar la variabilidad del conjunto de entrenamiento y reducir el sobreajuste se implementaron diversas técnicas de aumento de datos, entre las que se incluyen:

- Rotaciones aleatorias de hasta 25 grados.
- Variaciones de escala mediante zoom aleatorio de hasta 25%.
- Desplazamientos horizontales y verticales de hasta 20%.
- Volteo horizontal aleatorio.

Adicionalmente, el conjunto de entrenamiento fue dividido internamente en subconjuntos de entrenamiento y validación, utilizando una proporción 80/20.

## Arquitectura de la red convolucional

Para la tarea de clasificación de tumores cerebrales a partir de imágenes MRI, se diseñó una red neuronal convolucional profunda (CNN) utilizando la API secuencial de Keras. La arquitectura consta de cuatro bloques convolucionales, seguidos de capas completamente conectadas

Cada bloque convolucional está compuesto por:

- Una capa convolucional Conv2D con filtros de tamaño 3x3 y padding tipo same
- Una capa de Batch Normalization
- Una función de activación LeakyReLU.
- Una capa de MaxPooling con tamaño 2x2
- Una capa de Dropout, con tasas crecientes (0.25 a 0.40)



El número de filtros se incrementa progresivamente en cada bloque (32, 64, 128 y 256)

Posteriormente, las características extraídas son aplanadas mediante una capa Flatten y procesadas por una capa densa de 256 neuronas, acompañada nuevamente de Batch Normalization, activación LeakyReLU y una capa de dropout del 50%

Finalmente, la capa de salida consiste en una capa Dense con activación Softmax, cuyo número de neuronas coincide con el número de clases del problema (cuatro), permitiendo obtener una distribución de probabilidad para cada categoría.

El modelo fue compilado utilizando el optimizador Adam, . La función de pérdida seleccionada fue categorical cross-entropy y como métrica de evaluación principal se empleó accuracy.

Adicionalmente se emplean callbacks, siendo estos EarlyStopping para que la red se detenga el entrenamiento si el accuracy de validación no aumenta después de determinadas épocas y ModelCheckpoint que se usará para guardar los mejores modelos, pues el ultimo modelo/entrenamiento no siempre será el mejor.

## Resultados

El modelo de la red fue entrenado durante 100 épocas obteniendo en una de ellas un modelo que sobre test logró los resultados de

- **Accuracy:** 0.9027
- **Loss:** 0.2969

Estos valores indican que el modelo logró clasificar correctamente aproximadamente el **90.27%** de las imágenes MRI en el conjunto de prueba, lo cual representa un desempeño robusto. El valor de pérdida bajo sugiere una adecuada convergencia del modelo y una correcta asignación de probabilidades a las clases correspondientes.

En conjunto, estos resultados evidencian que la arquitectura propuesta es capaz de extraer características relevantes a partir de imágenes MRI T1-ponderadas y realizar una clasificación multiclase efectiva entre glioma, meningioma, tumor pituitario y ausencia de tumor.

## Discusión y limitaciones

El uso de modelos de aprendizaje profundo aplicados a imágenes de resonancia magnética cerebral representa una herramienta de alto potencial para apoyar el flujo de trabajo en los servicios de imagenología. En particular, un modelo de clasificación automática puede desempeñar un papel relevante como sistema de pre-análisis, previo a la evaluación definitiva por parte del médico especialista.

En un entorno clínico real, los departamentos de radiología y neurología enfrentan una alta carga de estudios, lo que puede generar retrasos en la interpretación de imágenes. La implementación de un modelo de clasificación basado en CNN permite realizar una evaluación preliminar automatizada, priorizando estudios con alta probabilidad de patología tumoral y facilitando la estratificación temprana de pacientes.

Este tipo de sistema no pretende sustituir el juicio clínico del radiólogo o neurólogo, sino actuar como un filtro inteligente, reduciendo el volumen de estudios que requieren revisión exhaustiva inmediata y apoyando la toma de decisiones clínicas iniciales. La capacidad del modelo para distinguir entre múltiples tipos de tumores cerebrales y casos sin tumor aporta valor clínico al proporcionar una primera aproximación diagnóstica de forma rápida y reproducible.

Además, el uso de modelos de este tipo puede contribuir a la homogeneización de criterios diagnósticos, minimizando la variabilidad interobservador y apoyando a médicos en formación o en contextos con acceso limitado a subespecialistas en neurorradiología.

A pesar de los resultados satisfactorios obtenidos, el modelo presenta diversas limitaciones que deben ser consideradas antes de su aplicación clínica:

1. Dependencia del dataset:

El modelo fue entrenado exclusivamente con el *Brain Tumor MRI Dataset*, el cual, puede no representar completamente la variabilidad real de estudios clínicos, tales como diferencias en equipos de resonancia, protocolos de adquisición o calidad de imagen.

2. Restricción al tipo de imagen:

El entrenamiento se realizó únicamente sobre imágenes MRI T1-ponderadas, lo que limita la capacidad del modelo para generalizar a otros tipos de secuencias comúnmente utilizadas en práctica clínica, como T2, FLAIR o contrastadas.

3. Clasificación y no segmentación:

El modelo se enfoca en la clasificación global de la imagen, sin proporcionar información sobre la localización o extensión del tumor, lo cual es fundamental para una evaluación clínica completa.

4. Ausencia de validación clínica prospectiva:

Los resultados obtenidos corresponden a evaluaciones offline; no se ha realizado una validación prospectiva en un entorno hospitalario real, lo cual es indispensable antes de su uso clínico.

Al identificar las limitaciones, se propone una línea de mejora para la profundización y uso real del modelo de nuestro proyecto:

- Uso de múltiples secuencias MRI  
Integrar diferentes secuencias de resonancia magnética para capturar información más completa del tejido cerebral y mejorar la capacidad de discriminación del modelo.
- Segmentación tumoral  
Extender el enfoque de clasificación hacia la segmentación automática del tumor, permitiendo identificar su localización y extensión
- Explicabilidad del modelo  
Incorporar métodos de interpretabilidad que permitan visualizar las regiones de la imagen relevantes para la predicción, favoreciendo la validación clínica.
- Validación clínica externa  
Probar el modelo con datos de distintas instituciones y equipos de resonancia para evaluar su robustez y capacidad de generalización en escenarios reales.

## Conclusiones

Con nuestro proyecto se logró cumplir satisfactoriamente el objetivo planteado. El modelo alcanzó un desempeño sólido, con una accuracy del 90.27% y una pérdida de 0.2969, demostrando una adecuada capacidad de generalización sobre datos no vistos.

Los resultados obtenidos evidencian que las CNN constituyen una herramienta eficaz para la clasificación automatizada de imágenes médicas, y que su aplicación como sistemas de apoyo al diagnóstico puede contribuir a la reducción de la carga de trabajo en imagenología, optimizando tiempos de respuesta y mejorando la eficiencia del proceso diagnóstico.

Si bien el modelo no reemplaza la evaluación médica especializada, su uso como herramienta de pre-análisis representa un paso importante hacia la integración de sistemas de inteligencia artificial en entornos clínicos reales. Futuras líneas de trabajo incluyen la incorporación de múltiples secuencias MRI, técnicas de interpretabilidad, segmentación tumoral y validación clínica prospectiva, con el fin de acercar el modelo a un escenario de aplicación hospitalaria real.

## Extra

Con el fin de un aprendizaje extra de como estos modelos pueden ser implementados en el mundo real y no solo se queden como notebooks o código Python, se realizó un API con FastAPI con el modelo, es decir, se crea una API para poder solo cargar una imagen y te muestre la predicción y la confianza de esta. Sumado a ello se utilizó Streamlit para crear una interfaz conectada a la API creada, esto para hacer mas amigable con el usuario. Tanto la API y la interfaz fueron subidas a un repositorio de Git y con ello subidas a internet haciendo uso de Railway y Streamlit community cloud.

Haciendo la interfaz solicitando la subida de la imagen, creando botones interactivos y un resultado que arroje la predicción principal con su confianza, y una tabla con las demás predicciones y sus probabilidades, sumado a ello un pequeño plotbar como se muestra en la imagen:

